

长程轨迹的两步门控 GRPO：数学流程

方法说明 · 中文版 · 2026-09-26 · 尚无实验结果

1 问题与数据

旧策略 π_{old} 已知。令 τ_i 为旧轨迹， R_i 为其终局奖励； s 是完整决策前缀， u 是下一步动作。筛选第一步优势接近零、后续动作分化明显的两步链。

2 任意状态的动作均值优势

$$I(s) = \{i : \tau_i \ni s\}, \quad K_s = |I(s)|, \quad \mathcal{U}(s) = \{a_i(s) : i \in I(s)\}$$

$I(s,u)$ 是经过 s 且选择 u 的轨迹集合。先在同一动作内平均终奖，再让不同动作等权； $d_s = |\mathcal{U}(s)|$ 。

$$q_s(u) = \frac{1}{n_s(u)} \sum_{i \in I(s,u)} R_i, \quad n_s(u) = |I(s,u)|$$

$$\bar{q}_s = \frac{1}{d_s} \sum_{u \in \mathcal{U}(s)} q_s(u), \quad \sigma_{q,s}^2 = \frac{1}{d_s} \sum_{u \in \mathcal{U}(s)} (q_s(u) - \bar{q}_s)^2$$

$$A_i^{\text{state}}(s) = \frac{q_s(a_i(s)) - \bar{q}_s}{\sigma_{q,s}} \quad (\sigma_{q,s} > 0)$$

同一 (s,u) 的轨迹共享 A^{state} 。若 $\sigma_{q,s} = 0$ ，该位置的回退优势定义为 0；训练时不对重复动作额外乘 $1/n_s(u)$ 。

3 两轮筛选与 Δ 门

$$\sigma_t = \sigma_{q,s_t}, \quad A_{1,i}(s_t) = A_i^{\text{state}}(s_t)$$

$$M_t = \lceil 0.2K_t \rceil, \quad C_t(s_t) = \{a_{i,t} : i \in \mathcal{L}_t(s_t)\}$$

在 s_t 按每条轨迹的 $|A_{1,i}|$ 取最小的 M_t 条，记为 $\mathcal{L}_t$ 。相同 a 的轨迹优势相同；若边界处整组纳入会超额，从并列轨迹中均匀随机、无放回地抽足名额。只有入选轨迹保留第一步 λ 资格。

$$s_{t+1} = (s_t, a), \quad \mathcal{I}_{t+1} = \{i : \tau_i \ni s_{t+1}\}, \quad d = |\mathcal{U}(s_{t+1})| \geq 5$$

对每个候选 a ，在子状态使用经过它的全部旧轨迹（不限于第一轮入选者）。若父或子状态的动作均值标准差为零，或子状态不同 a' 少于 5 个，则门控失败。

$$\sigma_{t+1} = \sigma_{q,s_{t+1}}, \quad G_\Delta(s_t, a) = \mathbf{1}\{\sigma_{t+1} \geq \omega\sigma_t\}$$

$$A_2(s_{t+1}, u) = \frac{q_{s_{t+1}}(u) - \bar{q}_{s_{t+1}}}{\sigma_{t+1}}$$

$$m(d) = \lceil d/2 \rceil, \quad |S(s_t, a)| = m(d)$$

仅当 $\sigma_{t+1} \geq \omega\sigma_t$ 时继续。 $S(s_t, a)$ 是按 $|A_2|$ 选出的前 $m(d)$ 个不同 a' ；截止值并列时随机抽足。 A_2 保留正负号。

4 门控与两步优势

$$G_t^{\text{act}}(s_t, a) = \mathbf{1}\{\sigma_t > 0\} \mathbf{1}\{a \in C_t(s_t)\} \mathbf{1}\{S(s_t, a) \neq \emptyset\}$$

$$B_{i,t} = \mathbf{1}\{i \in \mathcal{L}_t(s_t)\} G_t^{\text{act}}(s_t, a_{i,t})$$

任一后续条件失败时令 $S = \emptyset$ ，因此 $B_{i,t} = 1$ 必然意味着至少一个 a' 通过第二轮。相同 a 但未进入 $\mathcal{L}_t$ 的轨迹不会获得 λ 。

$$\Delta A_{i,t}^{(1)} = \lambda B_{i,t}, \quad \lambda > 0$$

$$\tilde{A}_{i,t+1} = [1 + (\beta - 1)I_{i,t+1}^S] A_2(s_{t+1}, a_{i,t+1}), \quad \beta > 1$$

第二步公式仅用于通过门控、且不与下一条两步链重叠的位置； I^S 表示该 a' 是否属于 S 。由于子状态的 $A^{\text{state}}=A_2$ ，未入选动作的系数是 1，入选动作的系数是 $\beta>1$ 。重叠位置沿用下式。

$$\widehat{A}_{i,j}^{\text{overlap}} = A_i^{\text{state}}(s_{i,j}) + \lambda + \beta I_{i,j}^S A_2(s_{i,j}, a_{i,j})$$

在重叠位置，第一步角色的 $A^{\text{state}}+\lambda$ 与上一链第二步角色的 $\beta I^S A_2$ 叠加。若该位置还属于上一链的 S ，动作级部分合计为 $(1+\beta)A_2$ 。

5 逐位置优势与 GRPO 更新

$$P_{i,j} = G_{j-1}^{\text{act}}(s_{i,j-1}, a_{i,j-1}), \quad I_{i,j}^S = \mathbf{1}\{a_{i,j} \in S(s_{i,j-1}, a_{i,j-1})\}$$

完整训练系数 $\widehat{A}_{i,j}$ 由以下五种互斥情况定义。边界位置不存在的上一门控取 0。

条件	$\widehat{A}_{i,j}$
$P=0, B=0$	$A_i^{\text{state}}(s_{i,j})$
$P=0, B=1$	$A_i^{\text{state}}(s_{i,j}) + \lambda$
$P=1, B=0, I^S=1$	$\beta A_2(s_{i,j}, a_{i,j})$
$P=1, B=0, I^S=0$	$A_i^{\text{state}}(s_{i,j})$
$P=1, B=1$	$\widehat{A}_{i,j}^{\text{overlap}}$

$$r_{i,j}(\theta) = \frac{\pi_{\theta}(a_{i,j} | s_{i,j})}{\pi_{\text{old}}(a_{i,j} | s_{i,j})}$$

$$\ell_{\text{clip}}(r, A) = \min\{rA, \text{clip}(r, 1 - \varepsilon, 1 + \varepsilon)A\}$$

$$J(\theta) = \mathbb{E} \left[\frac{1}{N} \sum_{i=1}^N \frac{1}{T_i} \sum_{j=1}^{T_i} (\ell_{\text{clip}}(r_{i,j}(\theta), \widehat{A}_{i,j}) - \kappa D_{i,j}^{\text{KL}}(\theta)) \right]$$

期望对 π_{old} 采样的轨迹组取。最大化 $J(\theta)$ ，或最小化 $-J(\theta)$ 。旧轨迹、奖励、门控和优势在一次更新中固定；梯度只经过当前策略比率及启用时的 KL 项。重复动作保留逐轨迹项，不额外按出现次数校正。 π_{old} 已知； κ 是否启用及其数值尚未设定。

$$D_{i,j}^{\text{KL}} = \frac{\pi_{\text{ref}}(a_{i,j} | s_{i,j})}{\pi_{\theta}(a_{i,j} | s_{i,j})} - \log \frac{\pi_{\text{ref}}(a_{i,j} | s_{i,j})}{\pi_{\theta}(a_{i,j} | s_{i,j})} - 1$$

上式是采用 DeepSeekMath 所给采样动作 KL 估计式时的写法； ε 为截断宽度， κ 为 KL 系数，均与第二步放大参数 β 不同。

6 计算顺序

收集旧轨迹 → 按完整状态与动作求 q 、 σ 、 A^{state} → 按轨迹选前 20% → 对子状态检查 $d \geq 5$ 、非零方差与 Δ 门 → 按 $|A_2|$ 选 $m(d)$ 个 a' → 逐位置分配 $\widehat{A}$ 并更新 θ 。

本文是理论流程记录。 ω 、 λ 、 β 的具体数值，以及动作对应 token 或完整步骤的映射，尚未设定；未报告实验结果。

原始 GRPO 目标参考：Shao 等，DeepSeekMath，arXiv:2402.03300。